Analiza skupień danych dotyczących cen mieszkań Metody

Analizy Danych - zadanie projektowe 1

Joanna Dagil (231008), Liliana Grześkiewicz (236138), Piotr Szpatusko (223420),
Adam Włodarski (230983)

rok akademicki 2025/2026

Spis treści

Streszczenie **2**

1 Wstęp **3**

2 Przedmiot badania **4**
2.1 Cel i zakres badania 4
2.2 Przegląd literatury 4
2.3 Zmienne wybrane do analizy 5
2.4 Wstępna analiza danych 6
2.4.1 Statystyki opisowe i podstawowa wizualizacja 6
2.4.2 braki danych 9
2.4.3 Obserwacje odstające 10

3 Opis metod **11**
3.1 wzory wraz z opisami oznaczeń 11
3.2 cytowanie pracy w której zaproponowano metodę/ewentualnie pracy, w której użyto metodę 11

4 Wyniki **12**

5 Podsumowanie **13**

6 Bibliografia **14**

Streszczenie

Projekt polega na analizie zbioru danych z Kaggle zawierającego oferty sprzedaży i najmu mieszkań z 15 największych miast w Polsce. Celem pracy jest wykorzystanie metody cluster do automatycznego wyodrębnienia grup podobnych ofert, ponieważ clustering należy do metod uczenia nienadzorowanego i służy do odkrywania ukrytych wzorców w danych bez gotowych etykiet. Dzięki temu można wskazać segmenty rynku mieszkaniowego różniące się poziomem cen oraz podobieństwem ofert między miastami. Taki projekt pomaga lepiej zrozumieć strukturę polskiego rynku mieszkań i stanowi dobrą podstawę do dalszej analizy trendów cenowych oraz porównań regionalnych.

Słowa kluczowe: analiza skupień, klastry, ceny mieszkań

Rozdział 1

Wstęp

Rynek nieruchomości w Polsce charakteryzuje się dużą dynamiką oraz znacznym zróżnicowaniem regionalnym. W obliczu stale rosnącej liczby ogłoszeń, tradycyjne metody przeglądania ofert stają się niewystarczające do pełnego zrozumienia mechanizmów rządzących tym sektorem. Niniejszy projekt podejmuje próbę uporządkowania i segmentacji tych danych przy użyciu zaawansowanych metod statystycznych.

Podstawę analizy stanowi zbiór danych pozyskany z serwisu Kaggle, obejmujący oferty sprzedaży oraz najmu mieszkań z 15 największych miast w Polsce. Ze względu na wielowymiarowość cech opisujących każdą nieruchomość, w pracy zdecydowano się na wykorzystanie metod uczenia nienadzorowanego.

Głównym celem projektu jest wykorzystanie metody analizy skupień do automatycznego wyodrębnienia grup podobnych ofert. Metoda ta pozwala na odkrywanie ukrytych wzorców w danych bez konieczności posiadania gotowych etykiet. Takie podejście umożliwia obiektywne wskazanie segmentów rynku mieszkaniowego, które różnią się poziomem cen oraz specyficznym podobieństwem cech fizycznych lokali.

W toku prac badanie zostało zawężone do rynku krakowskiego. Wybór Krakowa podyktowany jest faktem, że miasto to charakteryzuje się największą ilością ofert spośród wszystkich dostępnych miast, z wyłączeniem Warszawy. Większa ilość danych dostępnych dla tego regionu pozwala na uzyskanie bardziej reprezentatywnych wyników analizy skupień oraz lepsze zidentyfikowanie wzorców i grup w danych dotyczących cen mieszkań.

Realizacja projektu ma na celu:

- lepsze zrozumienie struktury polskiego rynku mieszkań;
- identyfikację kluczowych segmentów rynku różniących się poziomem cen;
- stworzenie solidnej podstawy do dalszej analizy trendów cenowych oraz porównań regionalnych.

Rozdział 2

Przedmiot badania

Badanie ograniczymy do jednego z miast z dostepnych danych. Analizując ilość wynajmów w poszczególnych miastach, wybieramy miasto z największą ilością wynajmów (oprócz Warszawy), co pozwoli nam na uzyskanie bardziej reprezentatywnych wyników analizy skupień. Na poniższym wykresie przedstawiono ilość wynajmów w poszczególnych miastach.

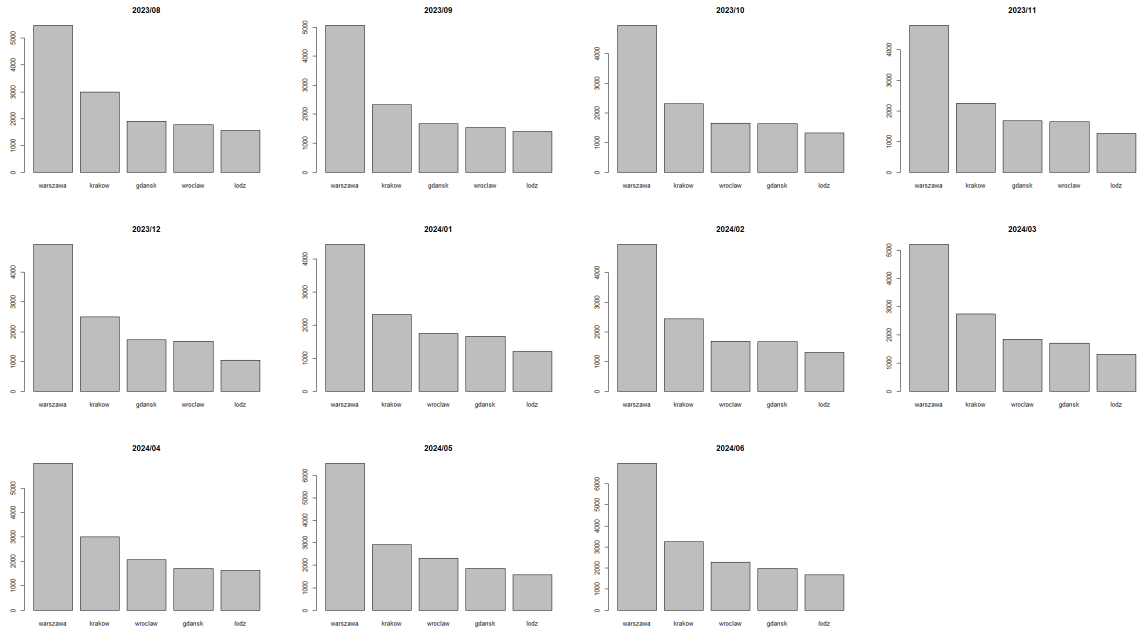

Rysunek 2.1: Ilość wynajmów w poszczególnych miastach z podziałem na miesiące

Miastem, które wybraliśmy do analizy jest Kraków, który charakteryzuje się największą ilością wynajmów spośród wszystkich miast (oprócz Warszawy). Wybór ten pozwoli nam na uzyskanie bardziej reprezentatywnych wyników analizy skupień, ponieważ większa ilość danych umożliwi lepsze zidentyfikowanie wzorców i grup w danych dotyczących cen mieszkań w Krakowie.

2.1 Cel i zakres badania

2.2 Przegląd literatury

(min. 1 cytowanie powiązane tematycznie i krótki opis co było badane)

2.3 Zmienne wybrane do analizy

W analizie przyjęto podział zmiennych diagnostycznych na symulanty i destymulanty z punktu widzenia atrakcyjności mieszkania. Symulantami nazywa się cechy, których wyższe wartości są oceniane pozytywnie, natomiast destymulantami są cechy, których wzrost wpływa niekorzystnie na ocenę obiektu. Dobór zmiennych miał na celu uwzględnienie zarówno cech fizycznych mieszkania, jak i elementów związanych z jego lokalizacją oraz dostępnością infrastruktury w otoczeniu.

Zmienne wybrane do analizy to:

Symulanty

1. `squareMeters` – powierzchnia mieszkania wyrażona w metrach kwadratowych

   Zmienna ta opisuje wielkość lokalu mieszkalnego i należy do podstawowych cech charakteryzujących nieruchomość. Powierzchnia mieszkania wpływa bezpośrednio na komfort użytkowania, możliwości aranżacyjne oraz funkcjonalność przestrzeni. Większy metraż daje zazwyczaj większą swobodę zagospodarowania wnętrza i lepiej odpowiada na potrzeby gospodarstw domowych o większej liczbie członków. Z tego względu zmienna `squareMeters` została zakwalifikowana jako symulanta.

2. `rooms` – liczba pokoi w mieszkaniu

   Zmienna określa liczbę wydzielonych pomieszczeń mieszkalnych w lokalu, a więc w pewnym stopniu odzwierciedla jego układ funkcjonalny. Liczba pokoi ma istotne znaczenie z punktu widzenia użyteczności mieszkania, ponieważ wpływa na możliwość oddzielenia poszczególnych stref życia codziennego, takich jak wypoczynek, sen czy praca. Mieszkania z większą liczbą pokoi są często bardziej atrakcyjne dla rodzin oraz osób pracujących zdalnie. Dlatego zmienna `rooms` została uznana za symulantę.

3. `poiCount` – liczba punktów zainteresowania w promieniu 500 metrów od mieszkania

   Zmienna ta opisuje intensywność i dostępność infrastruktury w bezpośrednim otoczeniu nieruchomości. Obejmuje ona liczbę punktów zainteresowania znajdujących się w promieniu 500 metrów od mieszkania, takich jak sklepy, punkty usługowe, restauracje, placówki edukacyjne, przystanki komunikacji miejskiej czy inne obiekty użyteczności codziennej. Wyższa wartość tej zmiennej wskazuje na lepsze wyposażenie okolicy w usługi i udogodnienia, co zwiększa wygodę życia mieszkańców oraz atrakcyjność lokalizacji. W związku z tym `poiCount` została zakwalifikowana jako symulanta.

4. `hasBalcony` – informacja o obecności balkonu w mieszkaniu

   Zmienna ta ma charakter jakościowy i informuje, czy mieszkanie posiada balkon. Balkon stanowi dodatkową przestrzeń użytkową, która może pełnić funkcję rekreacyjną, wypoczynkową lub praktyczną. Obecność balkonu jest często postrzegana jako cecha podnosząca standard mieszkania, szczególnie w zabudowie wielorodzinnej. Na potrzeby analizy zmienna ta może zostać zakodowana binarnie, na przykład jako 1 dla odpowiedzi `yes` oraz 0 dla odpowiedzi `no`. Po takim przekształceniu wyższa wartość oznacza cechę bardziej pożądaną, dlatego `hasBalcony` potraktowano jako symulantę.

Destymulanty

5. `price` – cena mieszkania

   Zmienna określa całkowitą cenę oferowanej nieruchomości i stanowi jedną z najważniejszych cech z punktu widzenia nabywcy. Cena wpływa bezpośrednio na dostępność ekonomiczną mieszkania oraz możliwość jego zakupu przez potencjalnych klientów. Przy porównywaniu mieszkań wyższa cena oznacza zwykle mniejszą dostępność finansową, nawet jeśli może częściowo wynikać z lepszej lokalizacji lub wyższego standardu. Z tego względu, w kontekście oceny atrakcyjności mieszkania z perspektywy ekonomicznej, zmienna `price` została uznana za destymulantę.

6. `centreDistance` – odległość mieszkania od centrum miasta w kilometrach

   Zmienna ta opisuje położenie nieruchomości względem centralnej części miasta. Lokalizacja jest jednym z kluczowych czynników wpływających na wartość i atrakcyjność mieszkania, ponieważ determinuje dostęp do miejsc pracy, usług, transportu publicznego, oferty handlowej i kulturalnej.

W warunkach dużego miasta mniejsza odległość od centrum jest zazwyczaj postrzegana jako cecha korzystna, gdyż wiąże się z lepszą dostępnością najważniejszych funkcji miejskich. Wobec tego wzrost wartości zmiennej `centreDistance` obniża atrakcyjność nieruchomości, dlatego została ona zakwalifikowana jako destymulanta.

2.4 Wstępna analiza danych

2.4.1 Statystyki opisowe i podstawowa wizualizacja

Tabela 2.1: Statystyki opisowe zmiennych wykorzystanych w analizie

	Srednia	Mediana	Minimum	Maksimum	OdchylenieStandardowe	Skosnosc
price	626 200.24	660 000.00	1 700.00	3 000 000.00	526 704.50	0.75
squareMeters	55.35	50.49	25.00	150.00	21.38	1.48
rooms	2.53	2.00	1.00	6.00	0.92	0.99
poiCount	24.35	14.00	0.00	212.00	33.62	2.99
centreDistance	3.82	3.71	0.14	9.99	2.17	0.38
hasBalcony	0.63	1.00	0.00	1.00	0.48	-0.55

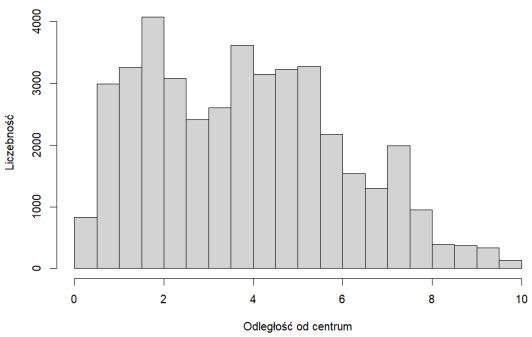

(a) Wizualizacja odległości mieszkań od centrum miasta

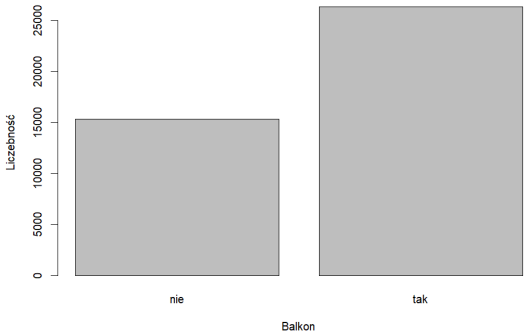

(b) Wizualizacja ilości mieszkań z balkonem i bez balkonu

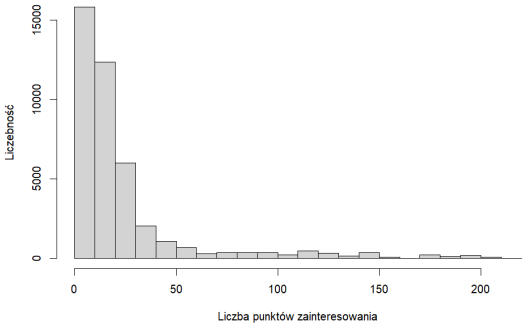

(c) Wizualizacja ilości punktów zainteresowania w promieniu 500 metrów od mieszkań

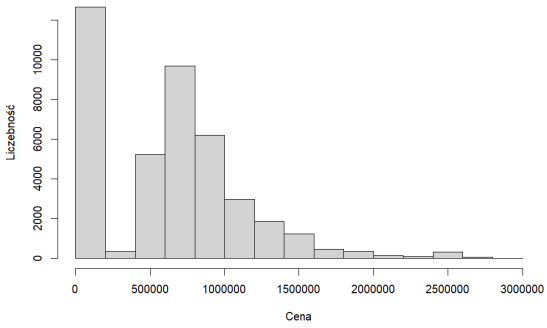

(d) Wizualizacja cen mieszkań

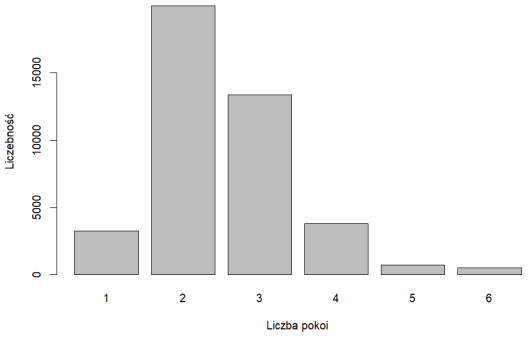

(e) Wizualizacja ilości pokoi w mieszkaniach

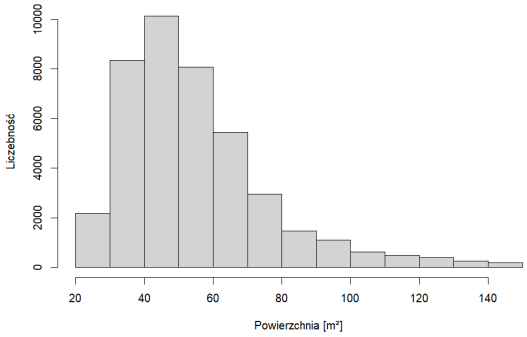

(f) Wizualizacja powierzchni mieszkań

Rysunek 2.2: Podstawowa wizualizacja zmiennych wykorzystanych w analizie

Statystyki opisowe oraz podstawowa wizualizacja zmiennych wykorzystanych w analizie umożliwiają ocenę struktury zbioru danych, rozkładu poszczególnych cech, stopnia ich zróżnicowania oraz ewentualnych nieregularności występujących w danych.

Rozkład zmiennej `price` oraz jej podstawowe charakterystyki statystyczne wskazują na obecność obserwacji należących do różnych segmentów rynku nieruchomości. Jest to związane z tym, że w zbiorze danych występują zarówno oferty mieszkań przeznaczonych na sprzedaż, jak i oferty mieszkań oferowanych na wynajem. Ze względu na brak bezpośredniej porównywalności cen najmu i cen sprzedaży, zakres dalszej analizy ograniczmy do ofert sprzedaży mieszkań.

Dokonujemy ponownych statystyk opisowych oraz wizualizacji, uwzględniając tylko oferty sprzedaży mieszkań. Dzięki temu uzyskamy bardziej spójny i porównywalny zbiór danych, który pozwoli na rzetelną analizę skupień oraz identyfikację grup podobnych ofert w kontekście cen mieszkań przeznaczonych na sprzedaż.

Tabela 2.2: Statystyki opisowe zmiennych wykorzystanych w analizie po usunięciu ofert wynajmu mieszkań

	Srednia	Mediana	Minimum	Maksimum	OdchylenieStandardowe	Skosnosc
price	897 888.77	795 000.00	255 000.00	3 000 000.00	394 185.67	1.89
squareMeters	57.17	52.00	25.00	150.00	22.12	1.43
rooms	2.63	3.00	1.00	6.00	0.95	0.91
poiCount	23.94	14.00	0.00	212.00	33.80	3.07
centreDistance	4.01	3.95	0.15	9.99	2.21	0.28
hasBalcony	0.62	1.00	0.00	1.00	0.49	-0.49

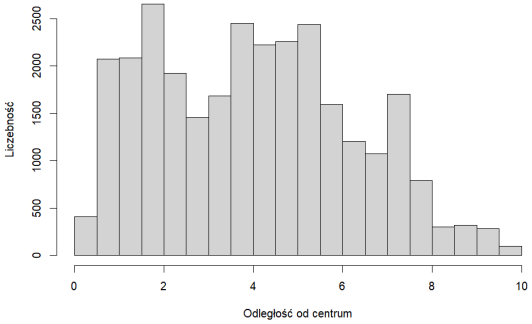

(a) Wizualizacja odległości mieszkań od centrum miasta

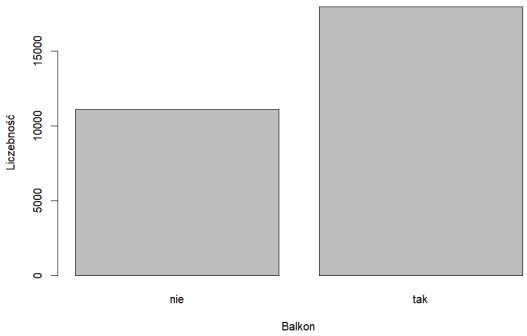

(b) Wizualizacja ilości mieszkań z balkonem i bez balkonu

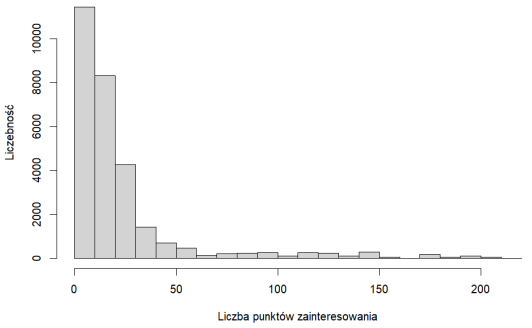

(c) Wizualizacja ilości punktów zainteresowania w promieniu 500 metrów od mieszkań

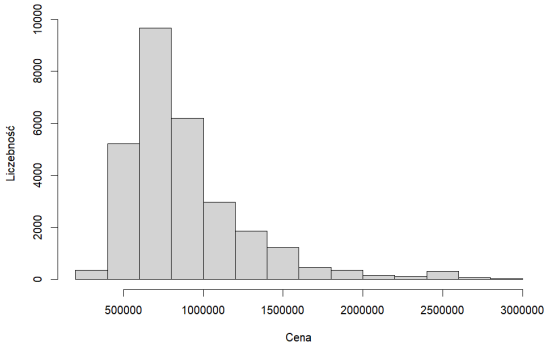

(d) Wizualizacja cen mieszkań

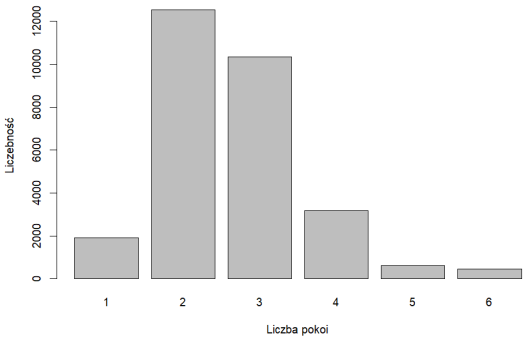

(e) Wizualizacja ilości pokoi w mieszkaniach

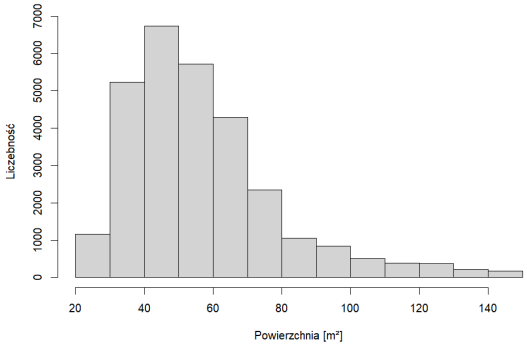

(f) Wizualizacja powierzchni mieszkań

Rysunek 2.3: Podstawowa wizualizacja zmiennych wykorzystanych w analizie po usunięciu ofert wynajmu mieszkań.

2.4.2 braki danych

Ocena kompletności danych stanowi istotny element wstępnej analizy zbioru, ponieważ obecność brakujących wartości może wpływać na wiarygodność wyników oraz ograniczać możliwość zastosowania wybranych metod statystycznych. Z tego względu sprawdzeniu poddano wszystkie zmienne uwzględnione w dalszej analizie, tj. `price`, `squareMeters`, `rooms`, `poiCount`, `centreDistance` oraz `hasBalcony`.

W analizowanych danych nie występują braki wartości dla żadnej z uwzględnionych zmiennych.

Każda obserwacja zawiera zatem pełny zestaw informacji wymaganych w dalszych etapach badania. Dzięki temu dalsza analiza nie wymaga ani uzupełniania danych, ani ograniczania zbioru do obserwacji kompletnych.

2.4.3 Obserwacje odstające

Analiza obserwacji odstających (ang. *outliers*) jest kluczowym etapem przygotowania zbioru danych, ponieważ algorytmy analizy skupień są szczególnie wrażliwe na wartości ekstremalne. Mogą one prowadzić do błędnej interpretacji wyników, przesuwając środki ciężkości tworzonych grup lub tworząc sztuczne, mało liczebne skupiska.

W celu identyfikacji obserwacji odstających zastosowano metodę rozstępu międzykwartylowego (IQR) oraz analizę wizualną za pomocą wykresów pudełkowych (*box-plots*). Proces czyszczenia danych skupił się na następujących aspektach:

- **Cena i powierzchnia:** Usunięto oferty, w których cena lub metraż przyjmowały wartości nierealne z punktu widzenia rynku nieruchomości (np. mieszkania o powierzchni powyżej 200 m^2 lub ceny jednostkowe drastycznie odbiegające od średniej rynkowej dla Krakowa). Wartości te mogły wynikać z błędów przy wprowadzaniu ogłoszeń.

- **Liczba pokoi:** Zweryfikowano rekordy, w których liczba pokoi była nieproporcjonalna do metrażu. Skupiono się na standardowych lokalach mieszkalnych, eliminując skrajne przypadki, które mogłyby zaburzyć strukturę budowanych skupień.

- **Dystans od centrum:** Sprawdzono poprawność zmiennej `centreDistance`, aby wykluczyć błędy w lokalizacji, które mogłyby sugerować położenie nieruchomości poza granicami badanego obszaru.

Ostatecznie, po usunięciu najbardziej skrajnych obserwacji, zbiór danych stał się bardziej spójny. Pozwoliło to na uzyskanie stabilniejszych wyników w dalszych etapach modelowania, zapewniając, że wyodrębnione skupienia będą reprezentować rzeczywiste segmenty rynku, a nie błędy w danych lub przypadki jednostkowe.

Rozdział 3

Opis metod

3.1 wzory wraz z opisami oznaczeń

3.2 cytowanie pracy w której zaproponowano metodę/ewentualnie pracy, w której użyto metodę

Rozdział 4

Wyniki

(w postaci tabelarycznej i/lub graficznej oraz omówienie wyników)

Rozdział 5

Podsumowanie

(ocena realizacji celu, odniesienie do pozycji z przeglądu literatury)

Rozdział 6

Bibliografia